

Tarea 3 - Reconocimiento de Patrones

Pablo Messina

Pontificia Universidad Católica de Chile, DCC, IMFD, IALab

Motivación - Tercera tarea del curso Reconocimiento de Patrones. El propósito de esta tarea es aplicar diferentes estrategias aprendidas en el curso para abordar una tarea de clasificación de parches de radiografía de tórax entre 3 posibles clases: Normal, Neumonía o COVID19, utilizando para ello un dataset recientemente armado a raíz de la presente contigencia sanitaria.

SOLUCIÓN PROPUESTA

Se decidió extraer 4 tipos de características: Local Binary Patterns (LBP), Histogram of oriented gradients (HOG), filtros de Gabor y texturas de Haralick. Para la extracción de todas estas características se hizo uso de la librería scikit-image (<https://scikit-image.org/>).

En el caso de LBP, se extrajo un vector de 59 dimensiones (58 bins de patrones uniformes y 1 bin para $256 - 58 = 198$ patrones no-uniformes). En HOG se obtuvo un vector de tamaño 128 ($4 \times 4 = 16$ grupos de 16×16 pixeles cada uno, con 8 orientaciones). En el caso de los filtros de Gabor se probaron todas las combinaciones de 2 frecuencias, 8 orientaciones y 2 desviaciones estándar, obteniéndose un vector de 64 dimensiones. Finalmente en el caso de Haralick se consideraron 3 distancias, 4 ángulos y 6 texturas (*contrast*, *dissimilarity*, *homogeneity*, *ASM*, *energy* y *correlation*), con lo cual se obtuvo un vector de 72 características. Por lo tanto, el vector final resultante es un vector de 323 características. Todas las características (columnas) del set de train se normalizaron restando la media y dividiendo por la desviación estándar. Estos mismos valores se re-usaron para normalizar las características en el set de test.

Luego, se decidió probar 5 estrategias diferentes:

1) PCA + KNN: se reduce dimensionalidad con PCA y luego se usa el método KNN (K nearest neighbors) para generar la clasificación.

2) MLP (1 hidden layer): se entrena un multi-layer perceptron (red neuronal) con sólo 1 capa oculta y 1 capa final de 3 salidas para clasificación.

3) SVM: se entrena una support vector machine para clasificación.

4) PCA + MLP (0/1 hidden layers): similar a la estrategia 2 pero antecendida por reducción de dimensionalidad con PCA y se considera la opción de no usar capas ocultas.

5) PCA + SVM: similar a la estrategia 3 pero antecendida por PCA.

EXPERIMENTOS REALIZADOS

Se usó grid search para probar diferentes combinaciones de hiperparámetros en cada una de las 5 estrategias. En el caso de PCA se probó distintos números de componentes para la

reducción de dimensionalidad. En KNN se probaron diferentes valores de K. En MLP se probaron diferentes tamaños de la capa oculta. En el caso de SVM, se probaron diferentes kernels. Para más detalles, referirse al código fuente que acompaña a este informe.

Para decidir el mejor set de hiperparámetros se utilizó como criterio el accuracy obtenido en el set de test, el cual se calculó a nivel de parches individuales y también agrupando los parches pertenecientes a una misma radiografía y tomando la clasificación mayoritaria como clasificación final.

Resumidamente, los resultados fueron los siguientes:

Estrategia	Patch acc.	Patch group acc.
1) PCA + KNN	0.7714	0.8810
2) MLP (1 hidden layer)	0.8968	0.9762
3) SVM	0.9056	0.9603
4) PCA + MLP (0/1 hidden layers)	0.9071	0.9841
5) PCA + SVM	0.8937	0.9603

Como vemos, los mejores resultados se obtuvieron con la estrategia 4. La figura 1 muestra las matrices de confusión correspondientes a la mejor versión (patch group accuracy = 0.9841).




Fig. 1. Matrices de confusión de mejor versión de la estrategia 4 según patch group accuracy. Esta versión usó PCA(60) y un MLP con un solo hidden layer de tamaño 5. Mejor visto en pdf con zoom.

CONCLUSIONES

De los resultados obtenidos podemos concluir que en la tarea particular de clasificación de radiografía de tórax con 3 clases es posible alcanzar un accuracy bastante alto en test (0.9841) combinando algoritmos heurísticos de extracción de características (HOG, LBP, Gabor, Haralick) con reducción de dimensionalidad (PCA) y aprendizaje automático de un clasificador (MLP con un solo hidden layer). También podemos observar que todas las estrategias que usan machine learning (2 a 5) son superiores a KNN (1) que usa una estrategia heurística. Esto indica que el aprendizaje automático puede ser ventajoso al permitir capturar de mejor manera las reglas implícitas aprendidas directamente de los datos.